

Documentație

By Mardaloescu Ana-Maria, Marian Andrada,
Matei Sergiu, Molnar Radu

Contents

1	Descrierea aplicației	2
2	Flow-ul aplicației	2
3	Descrierea plastică a problemei	2
4	Descrierea formală a problemei	2
5	Descrierea algoritmului	2
6	Descrierea Metodologiei	3
7	Architecture	4
8	Related work	5
8.1	Ana	5
8.2	Andrada	5
8.3	Sergiu	6
8.4	Radu	7

1 Descrierea aplicației

Un student la medicină dispune de o aplicație care îi prezintă vizual informații relevante despre inimă și malformațiile investigate și îl ajută să învețe despre acestea. Astfel, plecând de la informații preluate în format MRI, aplicația permite vizualizarea 3D a inimii, precum și a unor defecte posibile.

Vizualizând imaginea 3D (încărcată de către student) studentul poate verifica dacă există sau nu malformații ale inimii, iar dacă da, atunci identificarea acestora prin încercuire. La final, aplicația îi evidențiază malformația.

2 Flow-ul aplicației

Se pornește aplicația, se alege opțiunea de încărcare a imaginii în format nifti (.nii). Se încarcă imaginea și se dă check de către utilizator dacă acesta consideră ca inima din imagine prezintă malformații sau nu. Se transmite imaginea unui server unde se aplică un algoritm inteligent ce detectează malformația, după care este transformată în format 3D și trimisă înapoi la interfața cu utilizatorul, acesta având posibilitatea încărcării unei noi imagini.

3 Descrierea plastică a problemei

Pe baza unei imagini (MRI) a unei inimi se poate prezenta una dintre cele două cazuri: cazul normal sau cazul hypertrophic cardiomyopathy analizând imaginea la nivelul pixelilor.

4 Descrierea formală a problemei

Dezvoltarea unui algoritm ce realizează clasificarea inimilor dintr-o imagine MRI în cadrul a două clase: normal case și hypertrophic cardiomyopathy case.

Algoritmul analizează inima cu ajutorul unei rețele CNN și determină dacă inima este una sănătoasă sau nu.

5 Descrierea algoritmului

Am dezvoltat un algoritm ce folosește un CNN (Convolutional neural network) deoarece acesta este mai eficient decât o rețea neuronală clasică când vine vorba de

imagini(o imagine de 100x100, adica o matrice de 100x100, are 10000 de weight-uri pentru stratul 2). Operatia de convolutie consta in luarea unei sectiuni(3x3) din imagine() si aplicarea unei functii pe acea zona rezultatul urmand sa fie valoarea zonei. Polling-ul este o operatie a CNN care consta in luarea unei zone din matrice(2x2) si alegerea valorii maxime din acea zona pentru a forma noua matrice rezultat.CNN-ul are 3 straturi convolutionale 3x3 cu functii relu de activare, si 2 straturi de pooling de tip max, 2x2.

6 Descrierea Metodologiei

Pentru 50 de date din 4 categorii dintre care s-au ales 10 pentru test, s-a obtinut un rezultat de 0,20 acuratete. Algoritmul a rulat pentru 2, 5 si 10 epoci, obtinand rezultate mai proste cu cat mai multe epoci rula.

Faza 1: S-a folosit modelul secvential (stiva de straturi) impreuna cu 3 straturi Conv2D, fiecare cu filtre 64, dimensiunea pooling-ului de (3,3), functia de activare 'relu'. Pentru straturile de pooling s-a folosit MaxPooling2D cu dimensiune de (2,2). In final s-au adaugat 2 straturi Dense cu functia de activare 'relu' respectiv 'softmax'. S-au folosit 56 date de train, impartite in 4 categorii si 5 date de train. Datele au fost prelucrate folosind pickle. Pentru 3 epoci s-a obtinut o acuratete de 0.3 si un loss de 2.98. In cazul a 5 epoci s-a obtinut o acuratete de 0.44 si un loss de 1.42. Pentru cazuri cu 10 epoci algoritmul face overfitt, acuratetea fiind 1, iar loss-ul 0.03. Posibile cauze: s-a presupus ca rezultatele ar putea fi influentate de neuniformizarea datelor, acestea fiind 'alese' astfel incat sa nu fie necesara interpolarea (date cu aceeasi dimensiune z) sau de numarul redus al acestora.

Faza 2: S-a incercat prelucrarea datelor in mod diferit, fara normalizare, dar cu o retea care sa primeasca ca si input 4 parametri fara constrangeri. La rularea algoritmului acesta se opreste in faza de train datorita memoriei prea putine.

Faza 3: Se incearca interpolarea lineara a datelor folosind 'interpolate' din biblioteca 'scipy'.

7 Architecture

Layers:	Layer	Type	Convolution	Channels	Stride	Options on layer
	1	convolutional	3x3	32	-	-
	2	pooling	-	-	-	max
	3	convolutional	3x3	64	-	-
	4	pooling	-	-	-	max
	5	convolutional	3x3	64	-	-
	6	flatten	-	-	-	-
	7	relu	-	-	-	64
	8	softmax	-	-	-	10

8 Related work

Fiecare student a căutat alte studii făcute în domeniu, care ar putea fi utile la realizarea acestui proiect.

8.1 Ana

Titlul studiului : Four-Chamber Heart Modeling and Automatic Segmentation for 3D Cardiac CT Volumes Using Marginal Space Learning and Steerable Features

Realizatori : Yefeng Zheng, Adrian Barbu, Bogdan Georgescu, Michael Scheuering, and Dorin Comaniciu

Date : 457 de volume cu cele 4 camere etichetate manual, provenite de la 186 de pacienți cu diferite boli cardiovasculare

Algoritmi folosiți : marginal space learning (MSL) și steerable features.

Concluzii și rezultate : o viteză medie de 4 secunde per volum pentru segmentarea celor 4 camere. Abordare generală de segmentare— se poate aplica pe mai multe organe.

8.2 Andrada

Titlul studiului : Deep Learning Techniques for Automatic MRI Cardiac Multi-structures Segmentation and Diagnosis: Is the Problem Solved?

Realizatori : Olivier Bernard, Alain Lalande, Clement Zotti, Frederick Cervenansky, Xin Yang, Pheng-Ann Heng, Irem Cetin, Karim Lekadir, Oscar Camara, Miguel Angel Gonzalez Ballester, Gerard Sanroma, Sandy Napel, Steffen Petersen, Georgios Tziritas, Elias Grinias, Mahendra Khened, Varghese Alex Kollerathu, Ganapathy Krishnamurthi, Marc-Michel Rohe, Xavier Pennec, Maxime Sermesant, Fabian Isensee, Paul Jager, Klaus H. Maier-Hein, Peter M. Full, Ivo Wolf, Sandy Engelhardt, Chrisitan F. Baumgartner, Lisa M. Koch, Jelmer M. Wolterink, Ivana Isgum, Yeonggul Jang, Yoonmi Hong, Jay Pa-

travali, Shubham Jain, Olivier Humbert, and Pierre-Marc Jodoin

Date : Datele de antrenament au fost furnizate de ACDC (Automatic Cardiac Diagnosis Challenge), 70 de imagini MRI cu inimi sănătoase și 30 cu inimi bolnave, iar datele de test au fost 50 imagini MRI

Algoritmi folosiți : Isensee a folosit o serie de atribute dinamice folosind o rețea neuronală cu 50 de multi-layere, iar pentru clasificare a folosit random forest

Concluzii și rezultate : Ca și rezultat s-a obținut o acuratețe de 0.92.

8.3 Sergiu

Titlul studiului : Screening for cardiac contractile dysfunction using an artificial intelligence-enabled electrocardiogram (Funcția contractilă a miocardului)

Realizatori : Zachy I. Attia, Suraj Kapa, Francisco Lopez-Jimenez, Paul M. McKie, Dorothy J. Ladewig, Gaurav Satam, Patricia A. Pelikka, Maurice Enriquez-Sarano, Peter A. Noseworthy, Thomas M. Munger, Samuel J. Asirvatham, Christopher G. Scott, Rickey E. Carter & Paul A. Friedman

Date : S-au folosit datele electrocardiogramelor a 44.959 pacienți ai clinicii Mayo pentru antrenare, care conțineau date și despre fracția de ejecție a ventriculului stâng. Testarea s-a făcut pe 52.870 de pacienți

Algoritmi folosiți : Clasificare folosind CNN , funcția de predicție definită ca fracția de ejecție $j = 35$

Concluzii și rezultate : Pe setul de test acuratetea a fost de 85.7%, specificitate de 85.7%, senzitivitate de 86.3% si AUC de 0.93

8.4 Radu

Titlul studiului :

- I** Dilated convolutional neural networks for cardiovascular MR segmentation in congenital heart disease, 2017
- II** Automated cardiovascular segmentation in patients with congenital heart disease from 3D CMR scans: Combining multi-atlases and level-sets, 2017

Realizatori :

- I** Jelmer M. Wolterink, Tim Leiner, Max A. Viergever and Ivana Isgum
- II** Rahil Shahzad, Shan Gao, Qian Tao, Oleh Dzyubachyk and Rob van der Geest

Date : HVSMR 2016 MICCAI challenge organizer

Algoritmi folosiți : O primă metodă pentru împărțirea inimii din imagine și pentru determinarea părților ei se poate folosi o segmentare tip atlas-based pentru învățarea zonelor pe baza unor cunoștințe anterioare (se poate folosi un gradient descrescător pentru potrivirea atlasului cu cea a imaginii). Pentru detecția mușchiului miocard se poate folosi o clusterizare cu 2 clase una pentru sânge iar cealaltă pentru mușchi. Această împărțire ne poate ajuta la determinarea bolilor congenitale. O a doua metodă găsită pentru rezolvarea acestei probleme ar fi folosirea unei rețele neuronale convoluționale. O astfel de rețea este perfectă pentru procesarea de imagini. Aceasta va fi antrenată să determine vasele de sânge și mușchiul miocard.

Concluzii și rezultate :

Metoda 1: Dice index de 0.89 pentru vasele de sânge și 0.75 pentru țesuturile miocardice.

Metoda 2: Dice index de 0.93 pentru vasele de sânge și 0.80 pentru țesuturile miocardice